

## 摘 要

本文介绍了推荐系统领域的概况，并描述了现在通常使用的三大推荐方法：基于内容的，协同过滤和混合推荐算法。本文还介绍了目前的推荐算法的各种限制，并讨论可能的扩展来改善推荐的能力和使推荐系统有更广泛的应用。这些扩展包括，除其他外，一种改善用户和物品的理解，合并上下文信息纳入推荐过程，支持多标准评级，并提供更灵活和更少的侵入型推荐。

**关键字：**推荐系统，协同过滤，评级评估方法，推荐系统扩展

## 目录

摘 要.....	1
目录.....	2
第一章 介绍.....	4
第二章 推荐系统调查.....	4
2.1 基于内容的推荐.....	6
2.1.1 内容限制分析.....	9
2.1.2 过于专门化.....	9
2.1.3 新用户问题.....	10
2.2 协同过滤算法.....	10
2.2.1 新用户问题.....	15
2.2.2.新物品问题.....	15
2.2.3 稀疏度.....	15
2.3 混合算法.....	16
2.3.1 结合分开的推荐.....	16
2.3.2 加入基于内容推荐系统特征的模型.....	16
2.3.3 加入协同过滤特征的基于内容模型.....	17
2.3.4 发展一个两者统一的模型.....	17
第三章 推荐系统的扩展功能.....	21
3.1 全面了解用户和物品.....	21
3.2 基于模型的推荐技术扩展.....	22
3.3 多维性推荐.....	23
3.4 多目标评分.....	25
3.5 无干扰的.....	26
3.6 灵活性.....	27
3.7 推荐有效性.....	27
3.8 其他扩展.....	28
第四章 总结.....	28

参考文献.....	29
-----------	----

## 第一章 介绍

推荐系统已经成为一个重要的研究领域自从第一篇关于协同过滤的论文在 1990 年费中期出现。已经做了很多工作在工学和学术界上在过去的 10 年发展中。对这个领域的兴趣仍然高居不下，因为它包含富问题研究领域，大量的实际应用解决信息过载的问题和提供个性化推荐，内容和服务。比如推荐图书，CDs 和其他的产品在亚马逊上。在 MovieLens 上推荐电影，和在 VERSIFI Technologies 上推荐新闻（以前的 AdaptiveInfo.com）。此外，一些厂商已经将推荐系统整合到他们的商业服务上。

然而,尽管所有的这些进步,目前的推荐系统仍然需要进一步改善，使得推荐方法更有效和适用于一个更广泛的实际生活应用,包括推荐假期,对投资者的特定类型的金融服务和推荐在商店产品通过一个“智能”的购物车。这些改进包括更好的方法来表现用户行为和信息对于推荐的物品，更多高级的推荐模型方法，在推荐过程中整合上下文，利用多标准评级，发展少侵入但是更灵活的依赖测试更有效的推荐系统。

在本文中，我们描述了各种方式来扩展推荐系统的功能。但是，在做这之前，我们首先提出一个关于艺术状态的全面调查在第二部分。然后，我们识别现在的推荐方法的不同限制和讨论一些初始的做法老扩展它们的能力在第三部分。

## 第二章 推荐系统调查

尽管推荐系统的根源可以追溯到广泛认知科学，近似理论，信息检索，预测理论，并和管理科学、消费者选择模型有关，推荐系统成为一个独立的研究领域在 1990 年代中期，当研究人员开始关注推荐系统的问题，就是依赖于评级结构。在大多数系统里，推荐系统的问题是减少没被用户看见的物品的评估问题。直观地，这个评估基于用户给的评级和其他的正式的描述信息。一旦我们可以评估这些未评级的物品，我们可以推荐给用户更高评级的物品。

更正式地，这推荐系统问题可以归纳如下： $C$  代表用户集合， $S$  代表所有可能推荐的物品集合，比如书籍，电影，或者饭店。这个  $S$  集合的可能物品会非常大，成百上千甚至数百万个物品在一些应用程序里，比如推荐的书籍或者 CD。类似地，

用户的集合也非常大——数百万在一些案例里。 $u$  是一个效用函数，用来测量物品  $s$  对用户  $c$  的有效性。比如： $u : C \times S \rightarrow R$ ， $R$  是一个已排好序的集合(比如：在一定范围内的非负整数或者实数)。然后，对于每一个用户  $c \in C$ ，我们想选择一个  $s' \in S$ ，使得用户效用更大。更正式：

$$\forall c \in C, s'_c = \arg \max_{s \in S} (u(c, s))$$

在推荐系统里，物品的效用通常被评分所代替，表明了一个特定的用户对特定物品的喜爱程度。比如：约翰·多伊给个电影“哈利波特”评 7 分（总分 10 分）。然而，正如前面所说，通常效用函数可以是任意函数，包括利润函数。根据不同的应用程序，效用  $u$  可有用户指定，这样通常就是用户评分。或者通过程序计算，通过一个基于利润的效用函数。

每个在集合  $C$  里面的用户元素可以根据不同的用户特征来定义属性，比如年龄，性别，收入，婚姻状况等。在简单的案例里，这个属性集合可以只包含一个单一（唯一）的元素，比如用户  $id$ 。类似的，每个在物品集合  $S$  里的元素也可以被定义一个特征集合。比如，在一个电影推荐系统里，每个电影不只是它的  $ID$ ，还有它的名字，类型，导演，发布年份，主要演员等。

推荐系统的核心问题在于效用  $u$  通常不是在整个  $C \times S$  空间上，而是仅仅在它的一些子集里。在推荐系统中，效用通常由评分确定，而初始化仅由之前的用户评分确定。比如，在电影推荐系统里（比如 [MovieLens.org](http://MovieLens.org)），一些电影的用户初始评分能看见。在表 1 里，

表 1 电影推荐系统的评分矩阵

c	K-PAX	Life of Brian	Memento	Notorious
Alice	4	3	2	4
Bob	$\emptyset$	4	5	5
Cindy	2	2	4	$\emptyset$
David	3	$\emptyset$	5	2

是一个对电影的用户-物品评分矩阵，评分范围 1~5。符号 " $\emptyset$ " 表示用户没有给相应的电影评分。所以，推荐引擎能够评估（预测）没有评分的电影/用户和提出问题建议根据这些预测。

从已知评分到未知评分的推荐通常由以下几步:1)指定启发式:定义了效用函数和经验验证其性能。2)评估效用函数来优化性能标准,比如均方误差。

一旦未评分被评估,实际的物品推荐对用户就从最高的评分里面选择。根据(1)。另外,我可以推荐最好的  $N$  个给用户或者一些用户个物品。

对没有评分的物品进行新的评分有很多方式,比如机器学习,近似理论,各种启发。推荐系统通常根据它们对评分的处理来分类,在下一节,我们将这样的分类,提出了在文学和将提供不同类型的推荐系统的调查。被普遍接受的推荐问题首次在【45】,【86】,【97】和这个问题已经被广泛研究。此外,根据推荐系统的原理,推荐系统通常分为以下几类:

- 基于内容的推荐:用户将会被推荐他过去喜欢的类似物品;
- 协同过滤推荐:用户将会被推荐商品其他相似用户在过去喜欢的东西;
- 组合推荐:这种方式结合协同过滤推荐和基于内容的推荐。

推荐系统除了预测一些物品的评分,还会推荐给用户他们未曾见过的物品(如以上所讨论),已经在基于偏好的过滤上做了一些工作,比如预测用户的相关偏好[22], [35], [51], [52]。比如,在一个电影推荐程序里,基于偏好的过滤推荐技术会侧重于预测电影正确的相关顺序,而不是它们的评分。然而,本论文主要侧重于评分的推荐,因为它是现在推荐系统里最流行的推荐方式。

## 2.1 基于内容的推荐

在基于内容的推荐方法,物品  $s$  对用户  $c$  的效用值  $u(c, s)$  是基于用户  $c$  对  $s_i \in S$  的和物品  $s$  的相似度来决定的。例如:在一个电影推荐程序里,为了推荐电影给用户  $c$ ,这基于内容推荐系统尝试去理解用户在过去评分高电影的共性(特定的演员,导演,类型,主题等等)。然后,仅和用户喜好相似程度高的电影才会被推荐给用户。

基于内容的推荐算法源于信息检索[7],[89]和信息过滤研究[10]。因为信息检索的进步和重大成就,过滤社区,几个基于文本的重要程序的重要性,许多现在的推荐系统侧重于推荐基于文本的物品推荐,比如文档,网站站点(URLs),和新闻消息。传统信息检索的改善来自包含用户品味,喜好,需要的特征属性。这属性信息可以直接从用户得出,比如,通过问卷调查或者暗中从他们一直的事物行为得出。

正式地, 让内容(s)成为一个物品特征属性, 比如, 一个关于物品  $s$  的属性描述集合  $s$ 。它通常是一些特征集合从物品, 然后被用于决定适当的物品推荐。正如前面所提到的, 基于内容的推荐系统大多数被设计为基于文本的物品推荐, 在这些系统里, 内容通常被描述为关键字。比如, 一个基于内容的推荐网页给用户的 Fab 系统, 把网页描述成 100 个最重要的关键字。相似地, 这 Syskill 和 Webert 系统用 128 个最具信息的词语来代表文档。在文档  $d_j$  里面“最重要的”(或者“最具信息的”)词语  $k_j$  取决于一些权重算法可以通过一些不同的方式来确定  $W_{ij}$ 。

一种众所周知的在信息检索里测量单词权重的方式就是术语频率/频率逆文档频率(TF-IDF), 测量方式定义如下: 假设推荐给用户的文档的词의总数是  $N$ , 关键词  $k_i$  出现  $n_i$  词, 同时, 假设  $f_{i,j}$  是关键词  $k_i$  在文档  $d_j$  出现的次数。然后  $TF_{i,j}$ , 频率(或归一化频率)文档关键字  $k_i$  的  $d_j$ , 被定义为

$$TF_{i,j} = \frac{f_{i,j}}{\max_z f_{z,j}}$$

最大的计算在于所有关键词  $k_z$  在文档里的频率  $f_z$ 。然而, 关键词出现在许多文档不是有助于区分相关和不相关的文档。因此, 逆文档频率(IDF)的测量经常结合使用简单的词频率(TF)。逆文档频率  $k_i$  通常定义为:

$$IDF_i = \log \frac{N}{n_i}$$

然后, 关键字  $k_i$  在文档中的 TF-IDF 权重通常定义为

$$w_{i,j} = TF_{i,j} \times IDF_i$$

文档内容定义  $d_j$  定义为

$$Content(d_j) = (w_{1j}, \dots, w_{kj})$$

如前所述, 基于内容的推荐系统推荐的物品是类似于用户过去喜欢的 [56],[69],[77]。特别是, 各种与之前被用户打分和最佳匹配的物品作为候选项目。更正式, 让 ContentBasedProfile $c$  成为用户  $c$  包含口味和偏好的个人资料。这些个人资料是通过分析用户之前看到的内容和用户评价, 通常利用信息检索的关键字分析

技术。例如,ContentBasedProfile(c)可以被定义为一个向量的权重( $w_{c1}, \dots, w_{ck}$ ),每个权重  $w_{ci}$  表示关键字  $k_i$  对用户  $k_i$  的重要性的和可以使用各种技巧从单独计算评价内容向量。例如,一些平均方法,如 Rocchio 算法[85],可以用来计算 ContentBasedProfile(c)作为从个别内容向量的“平均”向量[8],[56]。另一方面,[77]也经常使用使用贝叶斯分类器来估计一个文档。Winnow 算法[62]也已被证明能够适用这个目的,特别是在有许多可能特性的情况下[76]。

在基于内容的系统中,效用函数  $u(c,s)$  通常被定义为:

$$u(c, s) = \text{score}(\text{ContentBasedProfile}(c), \text{Content}(s))$$

使用上述提到的信息摘要范例来推荐网页,网站网址,或新闻消息,用户  $c$  的 ContentBasedProfile 和文档  $s$  的 Content(s)可以表示成 TF-IDF 的关键字权重向量  $\vec{w}_c$  和  $\vec{w}_s$ 。此外,效用函数  $u(c,s)$  通常代表一些得分启发式信息检索文献中定义的向量  $\vec{w}_c$  和  $\vec{w}_s$ ,比如余弦相似性度量[7],[89]:

$$u(c, s) = \cos(\vec{w}_c, \vec{w}_s) = \frac{\vec{w}_c \bullet \vec{w}_s}{\|\vec{w}_c\|_2 \times \|\vec{w}_s\|_2}$$

$$= \frac{\sum_{i=1}^K w_{i,c} w_{i,s}}{\sqrt{\sum_{i=1}^K w_{i,c}^2} \sqrt{\sum_{i=1}^K w_{i,s}^2}}$$

$K$  表示在系统中关键字的总个数。

例如,如果用户  $c$  读许多关于生物信息学主题的在线文章,然后基于内容的推荐系统将能够向用户  $c$  推荐其他生物学信息的文章。这是因为这些文章比其他文章的主题将有更多生物信息学关联条件(如“基因组”,“排序”、“蛋白质组学”),因此,ContentBasedProfile(c),被向量  $\vec{w}_c$  所定义,将表示这些高权重的物品  $k_i$ 。因此,推荐系统使用余弦相似或相似的算法将分配更高的效用  $u(c,s)$  在  $\vec{w}_s$  给那些有很高生物信息学权重的文章  $s$  在和更低的效用值在生物信息学方面权重小得。

除了传统的基于信息检索方法的启发式,其他基于内容的推荐方法也被使用,如贝叶斯分类器[70],[77]和各种机器学习技术,包括聚类、决策树、人工神经网络[77]。这些技术不同于信息摘要的方法,因为它们计算效用预测不是基于启发式的公式,如余弦相似性度量,而是基于从底层数据模型使用统计和机器学习技术。例如,基于



一组为“相关”或“无关紧要”的 Web 页面[77], 使用朴素贝叶斯分类器[31]对未分级的网页进行分类。更具体地说,朴素贝叶斯分类器是用来估计页面  $P_j$  属于某个被给了一组关键词  $k_{1,j}, \dots, k_{n,j}$  的类  $C_i$  (如相关或不相关)的概率:

$$P(C_i | k_{1,j} \& \dots \& k_{n,j})$$

此外,[77]假设是关键字是独立的,因此,上面的概率对于下面的公式成正比

$$P(C_i) \prod_x P(k_{x,j} | C_i)$$

而关键词独立性假设并不一定适用于许多应用程序中,实验结果证明 naïve 贝叶斯分类器仍然产生高精度的分类[77]。此外,  $P(k_{x,j} | C_i)$  和  $P(C_i)$  可以从基础训练数据进行估计。因此,对于每个页面  $P_j$ , 概率  $P(C_i | k_{1,j} \& \dots \& k_{n,j})$  计算为每个类  $C_i$  和页面  $P_j$  分配给拥有最高概率的类  $C_i$  [77]。

虽然没有明确处理提供推荐, 检索社区贡献了几个技术被用于基于内容的推荐系统。这种技术的一个例子将是研究自适应过滤[101],[112],其重点是变得越来越准确识别相关文件通过逐步观察连续文档中的一个一个文件流。另一个例子是阈值设置[84],[111],其重点是确定文件的匹配程度与查询相关用户。其他文本检索方法[50],可以在文本检索会议(TREC)(<http://trec.nist.gov>)发现。

观察[8],[97],基于内容的推荐系统有一些局限性,在本节的其余部分描述。

### 2.1.1 内容限制分析

基于内容的限制在于这些系统推荐对象与特征明确相关。因此,为了有足够的特征,内容必须要么是在表单里可由计算机自动解析(如文本)或手动分配物品特性。而信息检索技术适用于从文本文档中提取特征,一些其他领域有自动特征提取的内在问题。例如,自动特征提取方法很难应用于多媒体数据,如图形图像、音频流和视频流。此外,由于资源的限制。它通常是不实际的手动分配属性[97]。

另一个限制内容分析是,如果两个不同的物品呈现相同的特征,它们是没有区别的。因此,由于基于文本的文件通常是由它们最重要的关键词,基于内容的系统之间不能区分这一篇写的好的文章和写得很糟糕的文章,如果他们使用相同的术语[97]。

### 2.1.2 过于专门化

当系统只能推荐根据用户资料取得高分的物品,用户仅限于被推荐类似之前已经评分的物品。例如,一个人没有希腊菜经验与不会收到城里最大的希腊餐厅的推荐。这个问题,在其他领域也被研究过,通常是通过引入一些随机处理。例如,使用遗传算法提出了一种可能的解决方案是上下文中信息过滤[98]。此外,过度专门化的问题不仅是基于内容的系统不能推荐任何用户之前没见过的物品。在某些情况下,与用户之前见过的太类似物品也不应该推荐给用户,比如不同的新闻文章描述相同的事件。因此,一些基于内容的推荐系统,如日报[13],过滤掉不同的从用户的偏好的新闻,而且用户见过太相似的物品也不该推荐给用户。此外,Zhanget al. [112]提供一组五个冗余措施来评估被认为是相关的文档是否包含一些新奇的信息。总之,建议的多样性往往是推荐系统需要的功能。理想情况下,用户应该提前设置一个范围的选项,而不是一组均匀的替代选项。例如,向用户推荐所有伍迪·艾伦的电影而用户只喜欢其中之一是没有必要的。

### 2.1.3 新用户问题

用户已经对足够物品评分后,基于内容的推荐系统才可以真正了解用户的喜好和给的用户提供可靠的推荐。因此,一个新的用户,很少评分后,将无法获得准确的建议。

## 2.2 协同过滤算法

与基于内容的推荐方法不同,协同推荐系统(或协同过滤系统)试图为特定用户预测物品的效用基于被其他用户评分的物品。更正式,物品  $s$  对于用户  $c$  的效用值  $u(c, s)$  被估计基于那些分配给物品  $s$  被那些“相似”的相似用户  $u(c_j, s)$  的效用值。例如,在电影推荐应用程序中,为了向用户推荐电影  $c$ ,协同推荐系统试图找到用户  $c_j \in C$  的“共同爱好者”,即电影中,其他用户也有类似的品味(给相同的电影评分相同)。然后,给用户  $c$  推荐他的“共同爱好者”最喜欢的电影。

有很多在学术界与产业界发展的协同过滤系统。可以说,格兰迪系统[87]是第一个推荐系统,提出使用原型作为一种机制来基于对每个信息量有限用户构建用户模型。使用原型,格兰迪系统将构建个人用户模型和每个用户使用它们来推荐相关书

籍。后来,Tapestry 系统依赖于每个用户人工识别志同道合的用户[38]。GroupLens[53],[86],视频推荐系统[45],林格[97]是第一个使用协同过滤算法的系统来自动预测。其他协同推荐系统的例子包括这本从亚马逊的书,这个 PHOAKS 系统,帮助人们在万维网[103]找到相关信息,和杰斯特系统推荐笑话[39]。

根据[15], 协同过滤算法可以大体上分为两类:基于记忆的推荐算法(或启发式推荐算法)和基于模型推荐算法。

启发式推荐算法[15],[27],[72],[86],[97]基本上是启发式做出评分预测基于整个以前由用户评分项目的集合。即未知物品的评分  $r_{c,s}$ ;为用户  $c$  和物品  $s$  通常是计算为一个其他用户对同一物品评分的集合(通常, $N$  最相似):

$$r_{c,s} = \text{aggr}_{c' \in C} r_{c',s}$$

$C$  表示一组  $N$  用户最类似于用户  $C$  和那些评价物品  $S(N$  的范围可以从 1 到所有用户的数量)。聚合函数的一些例子:

$$(a) \quad r_{c,s} = \frac{1}{N} \sum_{c' \in C} r_{c',s}$$

$$(b) \quad r_{c,s} = k \frac{1}{N} \sum_{c' \in C} \text{sim}(c, c') r_{c',s}$$

$$(c) \quad r_{c,s} = \vec{r}_c \cdot k \frac{1}{N} \sum_{c' \in C} \text{sim}(c, c') \times (\vec{r}_{c',s} - \vec{r}_{c'})$$

$k$  表示为归一化因子, 通常,  $k = 1 / \sum_{c' \in C} |\text{sim}(c, c')|$ , 用户  $c$  的平均评分,  $\vec{r}_c$  在(10c)定义为

$$\vec{r}_c = (1 / |S_c|) \sum_{s \in S_c} r_{c,s}, \text{ where } S_c = \{s \in S \mid r_{c,s} \neq \emptyset\}$$

在最简单的情况下,聚合可以是一个简单的平均水平,被(10a)定义。然而,最常见的聚合方法是使用加权和,(10b)所示。用户  $c$  和  $c'$  之间的相似性度  $\text{sim}(c, c')$ ,本质上是一个距离和重量测量,即,用户  $c$  和  $c'$  越相似,权重评级  $r_{c',s}$  就越大,  $s$  将会在  $r_{c,s}$  的预测里出现。注意,  $\text{sim}(x, y)$  是一种启发式的工件,它被介绍为了能够区分用户相似性度(即为每个用户能够找到一组“最亲密的同伴”或“最近的邻居”),同时,简化评分过程。如(10b)所示,不同的推荐应用程序可以使用自己的用户相似性度量方法,只要

计算使用的是归一化因子  $k$  来归一化,如上所示。两种最常用的相似性措施将在下面进行介绍。在(10b)使用加权和问题,是它没有考虑到这样一个事实:不同的用户可以使用不同的评定量表。调整后的加权,如(10c)所示,已被广泛用于解决这种限制。在这种方法中,不使用评级的绝对值,使用加权和使用他们偏离的平均评分对一致性用户。克服不同用户的评分范围是部署个性化过滤[22],[35],[51],[52],其重点是预测的用户的相对喜欢而不是绝对评分,在第二节早些时候指出过。

已有多种方法被用来计算用户之间相似性  $sim(c, c')$  在协同过滤系统里。在这些方法中,两个用户之间的相似度是基于他们对同一物品的评分。两种最流行的方法是相关和余弦。为了表现它们,让  $s_{xy}$  所有物品的集合都由用户  $x$  和  $y$  制作,即  $S_{xy} = \{s \in S \mid r_{x,y} \neq \emptyset \ \& \ r_{y,s} \neq \emptyset\}$ , 在协同过滤系统里,  $s_{xy}$  主要作为中间结果用于计算用户  $x$  的“最近邻居”和通常以简单明了的方式计算,即通过计算集合  $s_x$  和  $s_y$  的交集。然而,一些方法,比如用协同过滤方法[4],可以确定  $x$  的最近的邻居不通过为所以的用户计算  $s_{xy}$ 。在基于相关性的方法中,皮尔森相关系数是用来衡量相似度[86],[97]:

$$sim(x, y) = \frac{\sum_{s \in S_{xy}} (\vec{r}_{x,s} - \vec{r}_x)(\vec{r}_{y,s} - \vec{r}_y)}{\sqrt{\sum_{s \in S_{xy}} (\vec{r}_{x,s} - \vec{r}_x)^2 \sum_{s \in S_{xy}} (\vec{r}_{y,s} - \vec{r}_y)^2}}$$

在基于余弦的方法[15],[91],两个用户  $x$  和  $y$  是视为  $m$  维空间中的两个向量,其中  $m = |S_{xy}|$ 。然后,可以测量两个向量之间的夹角来进行相似度的计算:

$$sim(x, y) = \cos(x, y) = \frac{\vec{x} \bullet \vec{y}}{\|\vec{x}\|_2 \times \|\vec{y}\|_2} = \frac{\sum_{s \in S_{xy}} r_{x,s} r_{y,s}}{\sqrt{\sum_{s \in S_{xy}} r_{x,s}^2} \sqrt{\sum_{s \in S_{xy}} r_{y,s}^2}}$$

在  $\vec{x} \bullet \vec{y}$  表示向量  $\vec{y}$ ,  $\vec{x}$  之间的点积.还有另一种方法来测量用户之间相似性测量使用均方不同在【97】里面有描述。注意,不同的推荐系统可能采取不同的方法来实现用户相似性计算和尽可能有效的进行物品评分。一个常见的策略是提前计算所有用户相似性计算  $sim(x, y)$ , (包括  $s_{xy}$  的计算),仅偶尔重新计算(因为同行的网络通常不会在短时间内急剧变化)。然后,当用户要求推荐,评分可以使用预先计算的相

似度来进行需求的有效性计算。

注意,基于内容的推荐方法和协同方法从信息检索文献使用相同的余弦度量。然而,在基于内容的推荐系统,它是用来测量相似度在 **TF-IDF** 权重向量间,然而,在协同推荐系统中,在实际的用户实际评分向量建进行相似度的计算。

许多性能改善修改,如默认投票,逆用户频率、放大[15],和权重预测[27],[72],提出了这些基于相关和基于余弦的技术标准的扩展。例如,默认投票[15]是一个扩展上述基于启发式推荐的方法。观察到,只要有相对较少的用户指定的评分,这些方法将不适用于计算用户  $x$  和用户  $y$  之间的相似性尽管在物品交集上用相似的测量方法,即被两个用户  $x$  和  $y$  评分的物品集,经验表明,如果我们假设一些缺失的评分,评分预测精度可以提高[15]

同时,上述技术传统地被用来计算用户之间的相似性,萨瓦尔等。[91]提出了使用相同的基于相关技术和基于余弦的技术来计算相似性物品而不是和获得评分。这个想法一直在[29]进一步扩展对于 **top-N** 推荐。此外,[29],[91]提供经验证据,基于物品的算法可以提供比传统的基于用户的协同方法更好的计算性能,同时,提供比基于用户的最好算法类似或更好的质量的算法。

与基于启发式的方法相比,基于模型的算法[11],[15],[37],[39],[47],[64],[75],[105]使用的评分集来级学习模型,然后使用它来做出评分预测。例如,[15]提出了一种概率的协同过滤方法,计算未知的评分:

$$r_{c,s} = E(r_{c,s}) = \sum_{i=0}^n i \times P_r(r_{c,s} = i | r_{c,s'}, s' \in S_c) C$$

假设评分值是整数 0 到  $n$ , 概率表达式是用户  $c$  会给特定的物品  $s$  的评分概率,考虑到用户的之前评分。估计这个概率,[15]提出两种概率模型:集群模型和贝叶斯网络。在第一个模型中,相同偏好的用户聚集成类。给定用户的类成员资格时,用户评分被假设为是独立的,即,模型结构是朴素的贝叶斯模型。类和模型的参数的数量被从数据得知。第二模型表示每个物品作为贝叶斯网络域中的节点,其中每个节点的状态对应于每个物品的可能的评分。两个网络的结构和条件概率从数据训练得知。这种方法的一个限制是,每个用户可以被聚类成单个簇,而另一些推荐程序可能从群集的用户分为几类的受益。例如,在书的推荐应用中,一个用户为工作可能有兴趣一个主题(例如编程)和为了感兴趣休闲的完全不同的主题(例如捕

鱼)。

此外,[11]提出了在一个机器学习框架中的协同过滤算法,其中,各种机器学习技术(如神经网络)加上特征提取技术(如奇异值分解,一个用于减少矩阵的维数的代数技术)可以使用。[15]和[11]基于模型的方法比较其与标准的基于启发式的方法,生成报告,在一些应用中,基于模型的方法在精准推荐的时候优于基于启发式的推荐系统。然而,在这两种情况下的比较是纯粹的经验,也没有基本的理论依据支持。

在其他文献里提出了其他多种基于模型的协同推荐方法。一个基于统计模型的协同过滤[105],和几种估计模型参数的不同的算法的比较,包括 k-means 聚类 and 吉布斯抽样。其他协同过滤方法包括贝叶斯模型[20],[37]一个概率的关系模型,线性回归[91],[75]最大熵模型。最近,大量的研究一直在试图完成在模型推荐过程中使用更复杂的概率模型。例如,Shani 等。[96]查看推荐过程作为一个连续的决策问题,提出利用马尔可夫决策过程(一个著名的随机建模顺序决策)技术来生成推荐。其他概率建模技术对于推荐系统包括概率潜在语义分析[47],[48]和多项混合物和使用生成语义学方面模型的潜在狄利克雷分配[64]。同样,Si 和金[99]使用概率潜在语义分析提出一种灵活的混合模型,允许建模的类显式的用户和物品两套的潜变量。此外,Kumar et al. [55]使用一个简单的概率模型来证明协作过滤与相对较少的每个用户的数据是有价值的,而且,在某些限制设置,简单的协同过滤算法可能是一样有效的最好的算法。

在基于内容的技术的情况下,基于模型的协同过滤技术和基于启发式方法之间的主要区别在于,基于模型的技术不是基于某些特设启发式规则进行效用(评分)的预测计算,而是相反,根据使用统计和机器学习技术的基础数据学到的一种模型,提出了一种结合基于启发式方法和基于模型的方法的方法,已经被证实,使用这种组合方法可以提供比仅基于启发式的或基于模型方法更好的推荐。

一种不同的方法来改善现有的协同过滤算法的性能是[108],使用一些技术处理输入的一组指定的评分,比如排除噪音,冗余,利用稀疏评分数据。实际结果表明我基于模型的协同过滤算法增加了准确性和提高了效率。提出输入选择技术可以帮助学习的基于模型的算法来解决从大数据库学习这一问题[108]。此外,在最新的发展中,[109],构成了概率的协同过滤方法,构成了另一种方法来将基于启发式的方法和

基于模型的方法。特别是,[109]提出 1)使用积极的学习方法学习每个用户偏好的概率模型和 2)在一个混合模型里使用用户的偏好来计算推荐。后者算法的最近一些想法是部署使用传统的基于启发式的算法。

单一的协同推荐系统没有基于内容的推荐系统的一些缺点。特别是,因为协作系统使用其他用户的推荐(评分),他们可以处理任何类型的内容和推荐任何物品,甚至那些与过去不同。然而,协同过滤系统有自己的局限性[8],[57],如下所述。

### 2.2.1 新用户问题

这是与基于内容的推荐系统同样的问题。为了准确的推荐,系统必须从用户给出的评分首先了解用户的喜好。一些技术提出了解决这一问题。它们中的大多数使用混合推荐方法,结合基于内容的推荐技术和协同过滤的推荐技术。在下一节中详细描述了混合推荐系统。另一种方法是在[83],[109],各种技术探索确定最好的(即大多数信息推荐系统)物品给新用户。这些技术使用的策略是基于物品普及,物品熵,用户个性化和组合上述方法[83],[109]。

### 2.2.2.新物品问题

定期向推荐系统添加新物品。协同过滤系统仅仅依靠用户的偏好提出推荐。因此,在新物品被大量的用户评分前,推荐系统将无法推荐。这个问题也可以使用混合推荐方法解决,在下一节中描述。

### 2.2.3 稀疏度

在任何推荐系统中,已取得的评分数量相比需要预测的评分数量是非常少的。从很少的示例中有效预测评分是很重要的。同时,协同推荐系统的成功取决于大量的用户的可用性。例如,在电影推荐系统中,可能有很多电影评分的只有几个人,这些电影将会被推荐的很少,即使少数用户给予了较高的评分。用户与其他人群相比不同寻常的的口味,没有任何其他用户特别是相似,会导致很少的推荐[8]。解决评分稀疏这个问题的一个方法是在计算用户相似使用用户特征信息。也就是说,两个用户不仅可以被认为是类似的,如果他们认为对同样的电影评分相似,而且如果他们属于基于人口统计学是相似的。例如,[76]使用的性别、年龄、地区代码,教育,就业信

息,在餐厅推荐的应用程序。这个扩展传统的协同过滤技术有时被称为“人口过滤”[76]。另一种方法,也探讨了提出了探索用户的相似[49],稀疏问题的解决是通过应用关联检索框架和相关扩散激活算法通过他们过去的交易和反馈。一种不同的方法来处理稀疏评分矩阵用于[11],[90],在降维技术,奇异值分解(计算),被用来减少稀疏的评分矩阵的维数。奇异值分解是一个著名矩阵分解方法,它提供了最好的原始矩阵的低秩近似[90]。

## 2.3 混合算法

几个推荐系统使用结合协同过滤算法和基于内容的推荐方法,这有助于避免基于内容和协同过滤算法系统的一些限制[8],[9],[21],[76],[94],[100],[105]。不同的方法将协同过滤算法和基于内容的推荐方法结合到一个混合推荐系统可以分类如下:

1. 分别实现系统过滤算法和基于内容的推荐算法,结合他们进行预测
2. 将基于内容的推荐方法的一些特征加入到协同过滤算法中
3. 将协同过滤算法的一些特征加入到基于内容的推荐算法中
4. 构建一个通用的统一模型共同基于内容的推荐算法和协同过滤算法特征。

所以上述的推荐系统,将在下面进行描述。

### 2.3.1 结合分开的推荐

建立混合推荐系统的一种方法是将实现协同过滤和基于内容的推荐分离。然后,我们可以有两个不同的场景。首先,我们可以把从不同的推荐系统的输出(评分)输入到一个基于线性或者投票策略的最终推荐系统。或者,我们可以使用其中一个推荐系统,在任何时候选择使用一个“更好的”推荐系统比其他基于一些“质量”指标。例如,DailyLearner 系统[13]选择具有更高自信的推荐系统,而[104]选择的一个土建是更符合过去的评分的用户。

### 2.3.2 加入基于内容推荐系统特征的模型

一些混合推荐系统,包括 Fab[8],通过内容“协同过滤”的方法,描述了在[76],是基于传统的协同过滤技术还维护基于内容推荐系统的用户的特征文件。这些基于内容的文件,而不是一般的评分物品,用于计算两个用户之间的相似度。正如在[76]



中提到,这允许克服一些单纯协同过滤算法导致的稀疏性问题,因为通常情况下,没有多少对用户一般会有大量的评分物品。这种方法的另一个好处是,用户可以建议一个项目不仅在这个项目是评分高,而且用户有相似的特征文件,也就是说,当这个物品相对于用户的特征文件有很高的评分[8],是非常好的[40],采用相似的方法在使用不同的过滤器-特殊基于内容分析用户而在协同过滤的表现传统的参与者。因此,评级的用户对一些过滤器的评分一致能够得到更好的推荐[40]。同样,[65]使用一种协作方法,传统的用户的评分向量会比纯粹的基于内容的预测更强与额外的评分。

### 2.3.3 加入协同过滤特征的基于内容模型

这类最受欢迎的方法是使用一些降维技术在一组基于内容的特征文件。例如,[100]使用潜在语义索引(LSI)来创建一个基于协同过滤算法视图的用户特征文件的集合,用户特征文件由词向量(如 2.1 节中讨论)展现,相比与纯粹的基于内容的方法性能得到改善。

### 2.3.4 发展一个两者统一的模型

近年来,许多研究人员都在研究方法。例如,[9]提出使用基于内容和协同特征(如。用户的年龄或性别或电影的流派)在一个基于规则的分类器。Popescul 等。Popescul 等[80]和 Schein 等。[94]提出一个统一的概率方法,结合协同过滤和基于内容的推荐,是基于概率潜在语义分析[46]。然而,另一种方法是提出[25]和[5],在贝叶斯混合效应回归模型,采用马尔可夫链蒙特卡罗方法用于参数估计和预测。特别是,[5]使用用户的个人信息和物品在一个统计模型估计未知对用户  $i$  和物品  $j$  的评分  $r_{i,j}$  :

$$r_{ij} = x_{ij}\phi + z_i\gamma_j + w_j\lambda_i + e_{ij}$$

$$e_{ij} \sim N(0, \sigma^2)$$

$$\lambda_i \sim N(0, \Lambda)$$

$$\gamma_i \sim N(0, \Gamma)$$

$i = 1, \dots, I$  ,  $j = 1, \dots, J$  表示用户和物品,特别地。 $e_{ij}$  ,  $\lambda_i$  和  $\gamma_j$  是引入的随机变量

表示影响噪声, 未被注意的用户的不同性的来源, 物品不同性的来源。 $x_{ij}$  是一个包含用户和物品特征的矩阵,  $z_i$  是一个用户特征的向量,  $w_j$  是一个物品特征的向量。这个模型的未知参数  $\mu, \sigma^2, \Lambda$  和  $\Gamma$  在已知的数据使用马尔可夫链蒙特卡罗方法估计得到。总之,[5]使用用户属性  $\{z_i\}$  组成一个用户特征文件的一部分, 物品属性  $\{w_j\}$  构成一个项目特征文件的一部分, 它们的结合  $\{x_{ij}\}$  评估一个物品的评分。

混合推荐系统也可以增强知识技术[17], 如案例推理, 以提高推荐精度和解决传统推荐系统的一些限制(如。新用户, 新项目问题)。例如, 基于知识的推荐系统之间 *entrepreneur*[17]使用一些关于餐厅领域的知识, 美食, 食品(如“海鲜”不是“素食”)向用户推荐餐馆。以知识为基础的系统的主要缺点是需要知识获取-一个许多人工智能应用程序的瓶颈。然而, 知识重新推荐系统已经开发应用, 现成的在一些领域知识结构化以机器可读的形式, 例如, 作为本体。例如, *Quickstep* 和 *Foxtrot* 系统[66]使用本体研究论文主题向用户推荐在线研究文章。

此外, 数篇论文, 如[8],[65],[76],[100], 以经验为主比较单纯协同过滤系统、基于内容的推荐系统和混合系统性能, 证实了混合方法比单纯的方法可以提供更准确的推荐。

## 2.4 概述和总结

如 2.1, 2.2 和 2.2 部分所述, 做了很多研究在很多推荐技术中在过去的几年中, 使用范围广泛的统计学、机器学习、信息检索等技术, 和其他一些很先进、最尖端的技术, 相比较早期的推荐系统, 利用协同过滤和基于内容的启发式。

表 2 传统推荐系统研究

推荐方法	推荐技术	
	基于启发式的	基于模型的
基于内容	常用的技术: TF-IDF(信息检索)	常用的技术: 贝叶斯分类器

	<p>聚类</p> <p>代表性研究例子:</p> <p>Lang 1995</p> <p>Balabanovic &amp; Shoham 1997</p> <p>Pazzani &amp; Billsus 1997</p>	<p>聚类</p> <p>决策树</p> <p>人工神经网络</p> <p>代表性研究例子:</p> <p>Pazzani &amp; Billsus 1997</p> <p>Mooney et al.1998</p> <p>Mooney &amp; Roy 1999</p> <p>Billsus &amp; Pazzani 1999,2000</p> <p>Zhang et al.2002</p>
协同过滤	<p>常用的技术:</p> <p>最近邻 (余弦, 相关)</p> <p>聚类</p> <p>图理论</p> <p>代表性研究例子:</p> <p>Resnick et al. 1994</p> <p>Hill et al. 1995</p> <p>Shardanand &amp; Maes 1995</p> <p>Breese et al.1998</p> <p>Nakamura et al.1999</p> <p>Delgado &amp; Ishii 1999</p> <p>Sarwar et al.2001</p>	<p>常用的技术:</p> <p>贝叶斯网络</p> <p>聚类</p> <p>神经网络</p> <p>线性回归</p> <p>概率模型</p> <p>代表性研究例子:</p> <p>Billsus &amp; Pazzani 1998</p> <p>Breese et al. 1998</p> <p>Ungar &amp; Foster 1998</p> <p>Chien &amp; George 1999</p> <p>Getoor &amp; Sahami 1999</p> <p>Pennock &amp; Horwitz 1999</p> <p>Goldberg et al.2001</p> <p>Kumar et al.2001</p> <p>Pavlov &amp; Pennock 2002</p> <p>Shani et al.2002</p> <p>Yu et al.2002, 2004</p>

		Hofmann 2003,2004 Marlin 2003 Si & Jin 2003
混合推荐	结合基于内容和协同过滤的使用：  线性回归预测评分 多样投票策略 将一个组件作为启发式的一部分 代表性研究例子： Balabanovic & Shoham 1997 Claypool et al.1999 Good et al. 1999 Pazzani 1999 Billsus & Pazzani 2000 Tran & Cohen 2000 Melville et al.2002	通过以下将基于内容和协同过滤结合：  将一个组件作为模型的一部分 建立一个统一的模型 代表性研究例子： Basu et al. 1998 Condcliff et al.1999 Soboroff & Nicholas 1999 Ansari et al.2000 Popescul et al.2001 Schein et al.2002

如上面所讨论的,推荐系统可分为 1)基于内容的、协同过滤的、或者混合的,根据使用的推荐方法,和 2)基于启发式的或基于模型,基于类型的推荐技术,用于评分估计。我们使用这两个正交维度分类的推荐系统的研究 2\*3 矩阵表 2 所示。

在这一节中描述的推荐方法多个应用程序里表现良好,包括推荐书籍,cd,和新闻文章[64],[88],和使用这些方法的“强有力的”的推荐系统,如部署在亚马逊的[61],MovieLens[67],和 VERSIFI 技术(AdaptiveInfo.com)[14]上的推荐系统。然而,协同过滤和基于内容的方法有一定的局限性,在本节的前面有所所述。此外,为了更好的推荐和能够使用推荐系统在更复杂类型的应用程序,比如假期或某些类型的金融服务,大部分在本节的方法需要重要的扩展。例如,即使对于一个传统的电影推荐应用程序中,[3]表明,通过扩展传统的基于启发式的协同过滤方法考虑上下文信

息,例如什么时候,什么地点,和与谁一起看电影看,由此产生的推荐系统胜过单纯的传统的协同过滤方法。许多真实的推荐应用程序,包括一些业务应用程序,如上面所描述的,可以说比电影推荐系统复杂许多,也需要考虑更多的因素。因此,需要为这些类型的推荐程序开发更先进的推荐方法更为紧迫。在下一节中,我们回顾各种扩展的推荐方法,以支持更复杂类型的推荐应用程序。

### 第三章 推荐系统的扩展功能

第二节中描述的和在表 2 中总结的推荐系统,可以扩展在几个方面,包括提高对用户和物品的理解,在推荐过程中结合上下文信息,支持 **multicriteria** 评分,并提供更灵活和更少干扰类型的推荐。这样更全面模型的推荐系统可以提供更好的推荐功能。在本节的其余部分,我们将描述该扩展也研究各种开发它们的机会。

#### 3.1 全面了解用户和物品

如[2],[8],[54],[105]所指出,大部分的推荐方法产生评分是基于有限的理解用户和物品,由用户和物品的特征文件决定的,没有充分使用用户的历史数据和其他可用的数据。例如,传统的协同过滤方法[45],[86],[97]不使用用户和物品特征文件用于推荐和完全依赖评分信息来做推荐。尽管有一些进展将用户和物品特征文件纳入早期的一些方法推荐系统[13],[76],[79],但是这些特征文件很简单,不使用一些更先进的分析技术。除了使用传统的特征文件特性,比如关键字和简单的用户人口统计[69],[77],更先进的分析技术基于数据挖掘[1],[34],签名序列[63]和[26],描述用户的兴趣可以用来构建用户的特征文件。另外,除了使用传统的武平特征特性,如关键字[9],[76],类似的先进的分析技术也可以用于构建全面的物品特征文件。关于推荐系统,先进的分析技术,是基于数据挖掘主要用于 **Web** 使用的上下文分析[59],[68],[110],即,发现导航网络使用模式(即页面视图序列)给用户提供更好的网站推荐;然而,这些技术没有在以评分为依据的推荐系统中广泛采用。

一旦用户和物品特征文件被构建,就可以根据这些特征文件和先前的评分定义一般的评分估计函数:用户  $i$  的特征被定义为一个矢量  $\mathbf{p}$  的特性,即  $\vec{c}_i = (a_{i1}, \dots, a_{ip})$ 。同时,让物品的特征被定义为一个向量  $\mathbf{r}$  的特征,即  $\vec{s}_j = (b_{j1}, \dots, b_{jr})$ 。我们故意不精确

定义特性  $a_{ij}$  和供  $b_{kl}$  的含义,因为他们不同的应用程序可以是不同的概念,如数字、类别、规则、序列等等。同时,让  $\sim c$  是用户特征文件的向量,即  $\vec{c} = (c_1, \dots, c_m)$ , 让  $\vec{s}$  是所有物品特征文件的一个向量,即  $\vec{s} = (s_1, \dots, s_n)$ 。然后,最一般的评分函数可以被定义为:

$$r'_{ij} = \begin{cases} r_{ij} (r_{ij} \neq \emptyset) \\ u_{ij} (R, \vec{c}, \vec{s}), (r_{ij} = \emptyset) \end{cases}$$

根据已知的评分  $R$ , 用户特征文件  $r'_{ij} = u_{ij} (R, \vec{c}, \vec{s})$ , 和物品特征文件来估计未知的评分  $R = \{r_{ij} \neq \emptyset\}$ 。我们可以用各种方法估算  $s'_c(r)$  效用函数,包括各种启发式,最近的邻居分类,决策树,样条方法,径向基函数、回归、神经网络和关系学习方法(自  $\vec{c}$  和  $\vec{s}$  矩阵或使用数据库技术, 关系表)。此外,我们想要指出,(16)介绍了最一般的模型,取决于一系列的输入,包括用户  $i(\vec{c}_i)$  的特点和其他用户  $\vec{c} = (c_1, \dots, c_m)$  物品的特征项  $j(\vec{s}_j)$ , 和可能还有其他物品  $\vec{s} = (s_1, \dots, s_n)$ , 所有其他用户的评分(选择)。因此,显然函数  $u_{ij}$  把第二节中的协同过滤算法、基于内容的算法, 混合推荐算法都包含进来了。然而,大多数现有的推荐系统函数  $u_{ij}$  仅依赖于整个输入空间的子集(小) $R = \{r_{ij} \neq \emptyset\}$  的一个很小的子集。例如,传统的基于启发式的协同过滤的函数  $u_{ij}$  不依赖于输入  $R$  和一个集合  $R_j$  和对  $N$  的最近邻居集  $r_{ij}$  和  $R_j^2$ 。

一个有趣的研究问题是扩展属性特征文件,定义的  $\vec{c}$  和  $\vec{s}$ , 利用上述更先进的分析技术,如规则,序列,基于签名的方法。

### 3.2 基于模型的推荐技术扩展

正如在第二节所讨论的,一些基于模型的方法提供严格的评分估计方法利用各种统计和机器学习技术。然而,数学和计算机科学的其他领域,比如数学逼近理论 [16],[73],[81],还可以有助于发展更好的评分估计方法(16)。一个逼近方法的示例定义函数  $u_{ij}$ (16)由图坦卡蒙径向基函数[16],[30],[92]构成, 定义如下:给定一组点的  $X = \{x_1, \dots, x_m\}$  ( $x_i \in IR^N$ ) 和未知函数  $f$  的值(如评分函数)在这些点上。如

$f(x_1), \dots, f(x_m)$ , 径向基函数  $r_f, X$  估计  $f$  的值在整个  $IR^N$ ,  $X(x_i) = f(x_i)$  就:

$$r_f, x^{(x)} = \sum_{i=1}^m \alpha_i \phi(\|x - x_i\|)$$

$\{\alpha_1, \dots, \alpha_m\}$  是  $IR$  的系数,  $\|x\|$  是一个标准(如  $L2$ ),  $\phi$  是一个正定函数, 即满足下面情况的函数:

$$\sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j \phi(\|x_i - x_j\|) > 0$$

对于所以在  $IR$  里面有区别的店  $x_1, \dots, x_m$  和所以  $IR^N$  的系数  $\alpha_1, \dots, \alpha_m$ 。然后,著名定理[92]表明,如果正定函数,然后存在一个唯一函数  $r_f, x$ ,  $r_f, x(x_i) = f(x_i)$  满,正定函数的一些流行的示例是:

1、  $\phi(r) = r^\beta$ ,  $\beta > 0$  是一个正奇数

2、  $\phi(r) = r^k \log(r)$ ,  $k \in IN$

3、  $\phi(r) = e^{-\alpha r^2}$ ,  $\alpha > 0$

径向基函数的优点之一是他们都被广泛地研究过了近似理论及其理论性质和利用径向基函数在许多实际应用已经很好地理解[16],[92]。因此,它应该是有趣的在推荐系统将它们应用于估计未知的评分。

在推荐系统使用径向基函数的一个警告是, 尽管是推荐空间  $\vec{c}$  和  $\vec{s}$  通常不会构成一个  $n$  维欧几里得空间  $IR$  空间,研究的挑战之一是扩展径向基方法从实数到其他域,并将它们应用到推荐系统问题。其他近似方法估算  $u_{ij}$  的适用性(16)构成了另一个有趣的研究课题。

### 3.3 多维性推荐

目前的推荐系统在二维  $User \times Item$  用户物品空间上.这使他们的只基于用户和物品信息来做推荐,不考虑额外的在一些应用程序可能是至关重要的上下文信息。然而,在许多情况下,某种产品对用户的效用可能显著依赖时间(如一年的时间,比如季节或月,或一周的某一天)。它也可能依赖于某人生产该产品。在这种情况下,它可能不能简单的向用户推荐商品,推荐系统必须采取额外的上下文信息,如时间,地点,

和用户所在的公司来进行产品的推荐。例如,推荐一个假期包时,系统还应该考虑时间,与用户的旅行计划,旅行的条件和限制,和其他上下文信息。作为另一个例子,一个用户可以有显著不同的偏好对不同类型的电影,她希望看到和男友在周六晚上去电影院而不是在周三晚上与她的父母在家看租赁电影。正如我们在[2]和[3]所讨论的,扩展传统的二维  $User \times Item$  物品空间的推荐方法到多维设置。此外,[43],在推荐算法里包含用户任务的知识可以在特定应用程序中可以带来更好的推荐。

为了将上下文信息考虑进来,在多维空间上定义效用函数,  $D_1 \times \dots \times D_n$  (相对的是传统的  $User \times Item$  的空间), 如:

$$u : D_1 \times \dots \times D_n \rightarrow R$$

然后,一个推荐系统的问题是选择一个特定的“什么”规模  $D_{iii}$  和“为谁”的不重复的规模空集。推荐元组,

$$\forall (d_{j1}, \dots, d_{jl}) \in D_{j1} \times \dots \times D_{jl}$$

$$(d_{i1}, \dots, d_{ik}) = \arg \max_{\substack{(d'_{i1}, \dots, d'_{ik}) \in D_{i1} \times \dots \times D_{ik} \\ (d'_{j1}, \dots, d'_{jl}) = (d_{j1}, \dots, d_{jl})}} u(d'_1, \dots, d'_n)$$

例如,在电影推荐系统的情况下,不仅需要考虑电影  $d1$  的特征和想看电影的人  $d2$  的特征,而且还需要考虑上下文信息 1)d3:在哪里以及如何看到这部电影(如在家,在电影院,在电视上,在视频或 DVD),2)d4:和谁看这部电影(例如。独自一人,女朋友/男朋友,朋友,父母,等等),3)d5:什么时候看电影(如。在工作日或周末,早上/下午/晚上好,在开幕之夜,等等)。正如前面所讨论的,每个组件  $d1$ 、 $d2$ 、 $d3$ 、 $d4$ 、 $d5$  可以被定义为一个向量的特征和整体效用函数  $u(d1; d2, d3, d4; d5)$  可能相当复杂,考虑各种交互作用的向量  $d1$ 、 $d2$ 、 $d3$ 、 $d4$  和  $d5$ 。

正如在[2],[3]中,许多二维推荐算法不能直接扩展到多维的情况。此外,[3]提出了基于减少的推荐方法只使用根据指定的上下文的评分标准的推荐。例如,推荐一部电影给想周六在电影院看的人,基于简单的方法将只使用可用的评分的可以在周六周日看的电影,如果它是确定从地点和时间数据的维度影响观众的行为。通过选择只推荐上下文相关的评分,多维数据集的基于简单的方法用户和物品是两个重要的维度。然后,任何第二节中描述的标准二维推荐方法可以用来产生一个推荐。因为这些推荐仅基于上下文相关的评分,这意味着建立一个本地模型产生具体信息推



荐。

另一个可能的方法来生产多维推荐将部署分层贝叶斯方法[5],它可以扩展从二维到多维的情况如下:不考虑二维情况下,定义在(15),在用户特征  $d_1$  与矢量子和项目特征与向量  $w_j$  和物品特征  $d_2$ ,我们还可以添加上下文集合  $d_3, \dots, d_n$ ,  $d_i = (d_{i1}, \dots, d_{ix_i})$  的特征向量维度  $D_i$ 。然后,评级函数  $r = u(d_1, d_2, \dots, d_n)$  扩展从(15)的线性组合  $d_1, d_2, \dots, d_n$  和还包括在这些维度(即行动影响。交互作用,所定义的矩阵  $\{x_{ij}\}$  在(15),应该扩展到包括其他维度)的交互影响。研究的挑战之一是使这些扩展可伸缩到很大的  $n$  值。

### 3.4 多目标评分

大多数当前的推荐系统处理单维评分,比如电影和书籍的评分。然而,在某些应用程序中,如餐厅推荐,将多维评分合并到推荐的方法中是至关重要的。例如,许多餐厅指南,比如 Zagat 指南,提供三个餐厅评分标准:食物,装饰和服务。虽然多维评分推荐系统尚未测试,他们已经在递归学习运筹学社区进行了广泛的研究[33],[102]。典型的多维优化问题的解决方案包括:

1. 发现帕累托最优解,
  2. 对多个维度进行线性组合,减少单维论优化问题,
  3. 优化和最重要的维度,转换其他的维度为限制。
  4. 连续优化一个维度,然后将它转化为约束条件,对其他维度重复以上步骤。
- 后面方法的一个例子就是连续的让步。

为了说明可以在推荐系统中使用这些方法,考虑方法 3 的应用问题向用户推荐餐馆  $\mathbf{r}$  基于用户的标准食品质量  $f_c(r)$ , 装饰  $d_c(r)$ , 和服务  $s_c(r)$ 。我们可以把食品质量  $f_c(r)$  作为主要维度和使用其它标准约束条件,即我们想要找到  $f_c$  最大值的餐馆  $\mathbf{r}$ , 受到  $d_c(r) > \alpha_c$  和  $s_c(r) > \beta_c$  的限制,  $\alpha_c$  和  $\beta_c$  是装饰和服务的最小值(比如,用户  $c$  不会去装饰和服务评分低于 10 超过 30 的任何餐厅,不考虑食物的质量)。这个问题是复杂的是应为我们通常不会有用户对装饰  $d_c(r)$  和服务  $s_c(r)$  评分的所有餐馆。

然后,推荐系统的任务是估计未知评分  $d_c'(r)$  和  $s_c'(r)$ ,如第二节中描述,使用评分估计方法,并找到所有的餐馆  $r$  满足约足  $d_c'(r) > \alpha_c$  和  $s_c'(r) > \beta_c$ 。一旦我们找到所有这些满足约束评分的餐馆,我们可以用那些餐馆来寻找  $f_c(r)$  最大。然而,作为装饰和服务评分,我们可能没有用户对食品评分  $f_c(r)$  的所有餐馆,因此,还需要使用一个评分估计程序来估计  $f_c(r)$  在做推荐之前。

我们相信上面提高的找到帕累托最优解集和连续的迭代方法单一准则优化对多准则问题是有趣和挑战性的问题。

### 3.5 无干扰的

很多推荐系统是侵入性的,他们需要显式的用户反馈,用户参与是很重要的。例如,推荐任何新闻组文章之前,系统需要获得大多数用户对之前读过的文章的评分。因为它是不切实际的引出许多用户评分的这些文章,一些推荐系统使用不干扰的评分确定方法,使用某些替代的来估计真正的评分。例如,用户花费的时间阅读新闻组文章可以作为文章的评分的一个替代。一些不干扰的获取用户反馈的方法提出了在[18],[53],[66],[74],[94]。然而,不评分(如时间阅读一篇文章)往往不准确,不能完全代替显式的用户提供的评分。因此,减少侵入性的问题,同时保持某种程度的准确性的推荐系统需要研究人员去解决。

探索侵扰性问题的一种方法是确定一个最优的评分系统对一个新用户。例如,在推荐任何电影之前,MovieLens.org 首先要求用户评分预定义的电影(如 20 部电影)。这个请求会在终端用户增加一定的成本建模,但是可以以不同的方式,最简单的模型是一个欲望模型(即每个电影评级的成本是  $C$  和评级的成本电影  $c \square_n$ )。然后,侵扰性的问题可以被制定为一个优化问题,试图找到一个最优的初始评分请求数量  $n$  作为:每增加一个额外的用户提供的评分的准确性(或者其他有效的测试),所以,推荐结果对用户是有利的,一个有趣的无干扰关联的研究,考虑将发展正式的模型来定义和测量的  $B(n)$ ,提供  $n$  初始评分来增加预测的准确性。一旦知道如何衡量  $B(n)$  (如通过推荐系统的预测精度测量),我们需要确定一个最优的初始评分  $n$  最大化表达式  $B(n) - C \square_n$ ,明确地, $n$  的最优值是达到当边际收益等于边际话费,即当

$\Delta B(n) = C$ 。假设下的最优解应该存在  $B(n)$  是单调递增函数与边际效益递减  $\Delta B(n)$  渐近收敛等于零。

另一个有趣的研究机会在于开发边际成本模型,比上述固定成本模型更先进,可能在推荐系统中包括一个成本/效益分析使用隐式和显式的评分。

最后,逐步选择好的训练数据建模的目的是主动学习的问题,这是一个相当机器学习研究领域,并提出了很多方法来解决这个问题[23],[24],[36],[58]。我们相信,将主动学习方法应用于解决无干扰问题构成了另一个有趣的研究机会。

### 3.6 灵活性

大部分的推荐方法是僵化的,他们是“硬连接”进入系统的,因此,仅支持一组预定义的和固定的推荐。因此,最终用户不能定根据他或她的需要定制推荐。这个问题已被确定在[2]和推荐查询语言(RQL)[2]解决它。RQL sql 语言表达灵活指定推荐请求。例如,请求“推荐给每个用户从纽约最好的三部电影超过两个小时”RQL 中可以表示为:

```

RECOMMEND Movie TO User
BASED ON Rating
SHOW TOP 3
FROM MovieRecommender
WHERE Movie.Length > 120
AND User.City = "New York".

```

同时,大部分的推荐系统推荐只是推荐个别物品给个人用户,不处理聚合。然而,重要的是要能够提供聚合推荐在许多应用程序中,如推荐品牌或产品类别对某些领域的用户。例如,旅游推荐系统可以向本科生(用户组)推荐从东北到佛罗里达度假(物品类别)在春假期间。支持聚合推荐的一个方法是利用基于 OLAP 的多维推荐方法[19]。基于 OLAP 系统自然支持聚集层次结构和在推荐系统初始部署方法基于 olap 的推荐方法[2],[3]。然而,更多的工作是需要开发一个更全面的理解如何使用 OLAP 方法的推荐系统,这是一个有趣的和具有挑战性的研究问题。

### 3.7 推荐有效性

发展良好的指标来衡量的推荐的有效性已被广泛的在推荐系统论文中解决。这项工作的一些例子包括[41]、[44],[69],[107]。在大多数的推荐系统论文中,推荐算法的性能评估通常是覆盖范围和精度指标。推荐系统能够预测覆盖的比例的[41]。精度的测量可以是统计和决策支持[41]。统计主要精度指标比较估计评分(比如在(16)中定义),对于在  $User \times Item$  矩阵中的实际评分  $R$ ,包括平均绝对误差(MAE),根均方预测和错误,和预测与评分的结合,相关性决策支持测量了推荐系统可以物品的预测(例如会被用户评分高的物品)。包括传统的 IR 测量预测(真正的“高”评分的百分比在那些被预测是“高”的推荐系统),回忆(正确预测“高”评级的比例在所有已知的评分是“高”),F-measure(调和平均数的精度和召回),和接受者操作特性(ROC)测量证明在真阳性和假阳性利率之间的权衡推荐系统[41]。

虽然流行,但这些经验评估测量有一定的局限性。一个限制是这些措施通常是测试数据上执行用户选择评分。然而,用户选择物品评分可能构成一个倾斜的样本,如用户可能主要是评分他们喜欢的物品。换句话说,实证评价结果通常只显示准确的推荐用户决定评分,而系统的能力恰当地评估随机物品(它应该能够在其正常的现实生活中的使用)并不是测试。可以理解的是,它是昂贵和费时的推荐系统与用户进行控制实验的设置,因此,实验,测试推荐系统的质量在一个公正的随机样本很少,例如。[69]。然而,高质量的实验是必要的,为了真正理解提出的推荐系统的好处和局限性。

此外,尽管对测量的推荐的准确性至关重要,前面提到的测量技术往往不充分捕捉“有用性”和“质量”的推荐。例如,[107]观察超市应用程序,推荐显而易见的物品(如牛奶、面包),消费者会购买无论如何也不会提高准确率;对于消费者也不会很有帮助。因此,同样重要的是开发考虑经济的测试方法来捕获推荐的业务价值,如投资回报率(ROI)和客户生命周期价值(LTV)测量[32],[88],[95]。开发和研究这些测量方法,弥补在这一节中描述的限制构成了一个有趣的和重要的研究课题。

### 3.8 其他扩展

其他重要的研究问题,在推荐系统论文中已经探讨了包括可解释性[12],[42],诚信[28],可伸缩性[4],[39],[91],[93],和隐私[82],[93]这些推荐问题。然而,因为内容的兼职我们不会审查这项工作也不会讨论这些领域的研究机会。

## 第四章 总结

推荐系统在过去的十年里取得了很大的进步,许多基于内容,协同过滤和混合方法和几个“强有力的”系统已经开发出来。然而,尽管所有的这些进步,本文调查目前的推荐系统还需要进一步的改进使推荐方法更有效的更广泛的应用。在本文中,我们综述了当前推荐的方法的各种限制并讨论了可能的扩展,可以提供更好的推荐功能。这些扩展包括等,提高用户和物品的建模,将上下文信息纳入推荐过程,对多维评分的支持,并提供更灵活的过程以及低侵入性的推荐。我们希望本文提出的问题将在推荐系统社区推进讨论下一代的推荐技术。

## 参考文献

- [1] G. Adomavicius and A. Tuzhilin, “Expert-Driven Validation of Rule-Based User Models in Personalization Applications,” *Data Mining and Knowledge Discovery*, vol. 5, nos. 1 and 2, pp. 33-58, 2001a.
- [2] G. Adomavicius and A. Tuzhilin, “Multidimensional Recommender Systems: A Data Warehousing Approach,” *Proc. Second Int’l Workshop Electronic Commerce (WELCOM ’01)*, 2001b.
- [3] G. Adomavicius, R. Sankaranarayanan, S. Sen, and A. Tuzhilin, “Incorporating Contextual Information in Recommender Systems Using a Multidimensional Approach,” *ACM Trans. Information Systems*, vol. 23, no. 1, Jan. 2005.
- [4] C.C. Aggarwal, J.L. Wolf, K-L. Wu, and P.S. Yu, “Hortling Hatches an Egg: A New Graph-Theoretic Approach to Collaborative Filtering,” *Proc. Fifth ACM SIGKDD Int’l Conf. Knowledge Discovery and Data Mining*, Aug. 1999.
- [5] A. Ansari, S. Essegai, and R. Kohli, “Internet Recommendations Systems,” *J. Marketing Research*, pp. 363-375, Aug. 2000.
- [6] J.S. Armstrong, *Principles of Forecasting—A Handbook for Researchers and Practitioners*. Kluwer Academic, 2001.
- [7] R. Baeza-Yates and B. Ribeiro-Neto, *Modern Information Retrieval*. Addison-Wesley, 1999.
- [8] M. Balabanovic and Y. Shoham, “Fab: Content-Based, Collaborative Recommendation,” *Comm. ACM*, vol. 40, no. 3, pp. 66-72, 1997.

- [9] C. Basu, H. Hirsh, and W. Cohen, "Recommendation as Classification: Using Social and Content-Based Information in Recommendation," *Recommender Systems. Papers from 1998 Workshop*, Technical Report WS-98-08, AAAI Press 1998.
- [10] N. Belkin and B. Croft, "Information Filtering and Information Retrieval," *Comm. ACM*, vol. 35, no. 12, pp. 29-37, 1992.
- [11] D. Billsus and M. Pazzani, "Learning Collaborative Information Filters," *Proc. Int'l Conf. Machine Learning*, 1998.
- [12] D. Billsus and M. Pazzani, "A Personal News Agent that Talks, Learns and Explains," *Proc. Third Ann. Conf. Autonomous Agents*, 1999.
- [13] D. Billsus and M. Pazzani, "User Modeling for Adaptive News Access," *User Modeling and User-Adapted Interaction*, vol. 10, nos. 2-3, pp. 147-180, 2000.
- [14] D. Billsus, C.A. Brunk, C. Evans, B. Gladish, and M. Pazzani, "Adaptive Interfaces for Ubiquitous Web Access," *Comm. ACM*, vol. 45, no. 5, pp. 34-38, 2002.
- [15] J.S. Breese, D. Heckerman, and C. Kadie, "Empirical Analysis of Predictive Algorithms for Collaborative Filtering," *Proc. 14th Conf. Uncertainty in Artificial Intelligence*, July 1998.
- [16] M.D. Buhmann, "Approximation and Interpolation with Radial Functions," *Multivariate Approximation and Applications*, N. Dyn, D. Leviatan, D. Levin, and A. Pinkus, eds., Cambridge Univ. Press, 2001.
- [17] R. Burke, "Knowledge-Based Recommender Systems," *Encyclopedia of Library and Information Systems*, A. Kent, ed., vol. 69, Supplement 32, Marcel Dekker, 2000.
- [18] A. Caglayan, M. Snorrason, J. Jacoby, J. Mazzu, R. Jones, and K. Kumar, "Learn Sesame—A Learning Agent Engine," *Applied Artificial Intelligence*, vol. 11, pp. 393-412, 1997.
- [19] S. Chaudury and U. Dayal, "An Overview of Data Warehousing and OLAP Technology," *ACM SIGMOD Record*, vol. 26, no. 1, pp. 65-74, 1997.
- [20] Y.-H. Chien and E.I. George, "A Bayesian Model for Collaborative Filtering," *Proc. Seventh Int'l Workshop Artificial Intelligence and Statistics*, 1999.

- [21] M. Claypool, A. Gokhale, T. Miranda, P. Murnikov, D. Netes, and M. Sartin, "Combining Content-Based and Collaborative Filters in an Online Newspaper," Proc. ACM SIGIR '99 Workshop Recommender Systems: Algorithms and Evaluation, Aug. 1999.
- [22] W.W. Cohen, R.E. Schapire, and Y. Singer, "Learning to Order Things," J. Artificial Intelligence Research, vol. 10, pp. 243-270, 1999.
- [23] D. Cohn, L. Atlas, and R. Ladner, "Improving Generalization with Active Learning," Machine Learning, vol. 15, no. 2, pp. 201-221, 1994.
- [24] D. Cohn, Z. Ghahramani, and M. Jordan, "Active Learning with Statistical Models," J. Artificial Intelligence Research, vol. 4, pp. 129-145, 1996.
- [25] M. Condliff, D. Lewis, D. Madigan, and C. Posse, "Bayesian Mixed-Effects Models for Recommender Systems," Proc. ACM SIGIR '99 Workshop Recommender Systems: Algorithms and Evaluation, Aug. 1999.
- [26] C. Cortes, K. Fisher, D. Pregibon, A. Rogers, and F. Smith, "Hancock: A Language for Extracting Signatures from Data Streams," Proc. Sixth ACM SIGKDD Int'l Conf. Knowledge Discovery and Data Mining, 2000.
- [27] J. Delgado and N. Ishii, "Memory-Based Weighted-Majority Prediction for Recommender Systems," Proc. ACM SIGIR '99 Workshop Recommender Systems: Algorithms and Evaluation, 1999.
- [28] C. Dellarocas, "The Digitization of Word of Mouth: Promise and Challenges of Online Feedback Mechanisms," Management Science, vol. 49, no. 10, pp. 1407-1424, 2003.
- [29] M. Deshpande and G. Karypis, "Item-Based Top-N Recommendation Algorithms," ACM Trans. Information Systems, vol. 22, no. 1, pp. 143-177, 2004.
- [30] J. Duchon, "Splines Minimizing Rotation-Invariant Semi-Norms in Sobolev Spaces," Constructive Theory of Functions of Several Variables, W. Schempp and Zeller, ed., pp. 85-100, Springer, 1979.
- [31] R.O. Duda, P.E. Hart, and D.G. Stork, Pattern Classification. John Wiley & Sons, 2001.

- [32] F.R. Dwyer, "Customer Lifetime Valuation to Support Marketing Decision Making," *J. Direct Marketing*, vol. 3, no. 4, 1989.
- [33] M. Ehrgott, *Multicriteria Optimization*. Springer Verlag, Sept. 2000.
- [34] T. Fawcett and F. Provost, "Combining Data Mining and Machine Learning for Efficient User Profiling," *Proc. Second Int'l Conf. Knowledge Discovery and Data Mining (KDD-96)*, 1996.
- [35] Y. Freund, R. Iyer, R.E. Schapire, and Y. Singer, "An Efficient Boosting Algorithm for Combining Preferences," *Proc. 15th Int'l Conf. Machine Learning*, 1998.
- [36] Y. Freund, H.S. Seung, E. Shamir, and N. Tishby, "Selective Sampling Using the Query by Committee Algorithm," *Machine Learning*, vol. 28, nos. 2-3, pp. 133-168, 1997.
- [37] L. Getoor and M. Sahami, "Using Probabilistic Relational Models for Collaborative Filtering," *Proc. Workshop Web Usage Analysis and User Profiling (WEBKDD '99)*, Aug. 1999.
- [38] D. Goldberg, D. Nichols, B.M. Oki, and D. Terry, "Using Collaborative Filtering to Weave an Information Tapestry," *Comm. ACM*, vol. 35, no. 12, pp. 61-70, 1992.
- [39] K. Goldberg, T. Roeder, D. Gupta, and C. Perkins, "Eigentaste: A Constant Time Collaborative Filtering Algorithm," *Information Retrieval J.*, vol. 4, no. 2, pp. 133-151, July 2001.
- [40] N. Good, J.B. Schafer, J.A. Konstan, A. Borchers, B. Sarwar, J.L. Herlocker, and J. Riedl, "Combining Collaborative Filtering with Personal Agents for Better Recommendations," *Proc. Conf. Am. Assoc. Artificial Intelligence (AAAI-99)*, pp. 439-446, July 1999.
- [41] J.L. Herlocker, J.A. Konstan, A. Borchers, and J. Riedl, "An Algorithmic Framework for Performing Collaborative Filtering," *Proc. 22nd Ann. Int'l ACM SIGIR Conf. Research and Development in Information Retrieval (SIGIR '99)*, 1999.
- [42] J.L. Herlocker, J.A. Konstan, and J. Riedl, "Explaining Collaborative Filtering Recommendations," *Proc. ACM Conf. Computer Supported Cooperative Work*, 2000.



- [43] J.L. Herlocker and J.A. Konstan, "Content-Independent TaskFocused Recommendation," IEEE Internet Computing, vol. 5, no. 6, pp. 40-47, Nov./Dec. 2001.
- [44] J.L. Herlocker, J.A. Konstan, L.G. Terveen, and J.T. Riedl, "Evaluating Collaborative Filtering Recommender Systems," ACM Trans. Information Systems, vol. 22, no. 1, pp. 5-53, 2004.
- [45] W. Hill, L. Stead, M. Rosenstein, and G. Furnas, "Recommending and Evaluating Choices in a Virtual Community of Use," Proc. Conf. Human Factors in Computing Systems, 1995.
- [46] T. Hofmann, "Probabilistic Latent Semantic Analysis," Proc. 15<sup>th</sup> Conf. Uncertainty in Artificial Intelligence, pp. 289-296, 1999.
- [47] T. Hofmann, "Collaborative Filtering via Gaussian Probabilistic Latent Semantic Analysis," Proc. 26th Ann. Int'l ACM SIGIR Conf., 2003.
- [48] T. Hofmann, "Latent Semantic Models for Collaborative Filtering," ACM Trans. Information Systems, vol. 22, no. 1, pp. 89-115, 2004.
- [49] Z. Huang, H. Chen, and D. Zeng, "Applying Associative Retrieval Techniques to Alleviate the Sparsity Problem in Collaborative Filtering," ACM Trans. Information Systems, vol. 22, no. 1, pp. 116-142, 2004.
- [50] D.A. Hull, "The TREC-7 Filtering Track: Description and Analysis," Proc. Seventh Text Retrieval Conf. (TREC-7), 1999.
- [51] R. Jin, L. Si, and C. Zhai, "Preference-Based Graphic Models for Collaborative Filtering," Proc. 19th Conf. Uncertainty in Artificial Intelligence (UAI 2003), Aug. 2003a.
- [52] R. Jin, L. Si, C. Zhai, and J. Callan, "Collaborative Filtering with Decoupled Models for Preferences and Ratings," Proc. 12th Int'l Conf. Information and Knowledge Management (CIKM 2003), Nov. 2003b.
- [53] J.A. Konstan, B.N. Miller, D. Maltz, J.L. Herlocker, L.R. Gordon, and J. Riedl, "GroupLens: Applying Collaborative Filtering to Usenet News," Comm. ACM, vol. 40, no. 3, pp. 77-87, 1997.

- [54] J.A. Konstan, J. Riedl, A. Borchers, and J.L. Herlocker, "Recommender Systems: A GroupLens Perspective," Proc. Recommender Systems, Papers from 1998 Workshop, Technical Report WS-98-08, 1998.
- [55] R. Kumar, P. Raghavan, S. Rajagopalan, and A. Tomkins, "Recommendation Systems: A Probabilistic Analysis," J. Computer and System Sciences, vol. 63, no. 1, pp. 42-61, 2001.
- [56] K. Lang, "Newsweeder: Learning to Filter Netnews," Proc. 12<sup>th</sup> Int'l Conf. Machine Learning, 1995.
- [57] W.S. Lee, "Collaborative Learning for Recommender Systems," Proc. Int'l Conf. Machine Learning, 2001.
- [58] D. Lewis and J. Catlett, "Heterogeneous Uncertainty Sampling for Supervised Learning," Proc. 11th Int'l Conf. Machine Learning, pp. 148-156, 1994.
- [59] J. Li and O.R. Zai'ane, "Combining Usage, Content, and Structure Data to Improve Web Site Recommendation," Proc. Fifth Int'l Conf. Electronic Commerce and Web Technologies (EC-Web '04), pp. 305-315, 2004.
- [60] G.L. Lilien, P. Kotler, and K.S. Moorthy, Marketing Models. Prentice Hall, 1992.
- [61] G. Linden, B. Smith, and J. York, "Amazon.com Recommendations: Item-to-Item Collaborative Filtering," IEEE Internet Computing, Jan./Feb. 2003.
- [62] N. Littlestone and M. Warmuth, "The Weighted Majority Algorithm," Information and Computation, vol. 108, no. 2, pp. 212- 261, 1994.
- [63] H. Mannila, H. Toivonen, and A.I. Verkamo, "Discovering Frequent Episodes in Sequences," Proc. First Int'l Conf. Knowledge Discovery and Data Mining (KDD-95), 1995.
- [64] B. Marlin, "Modeling User Rating Profiles for Collaborative Filtering," Proc. 17th Ann. Conf. Neural Information Processing Systems (NIPS '03), 2003.
- [65] P. Melville, R.J. Mooney, and R. Nagarajan, "Content-Boosted Collaborative Filtering for Improved Recommendations," Proc. 18th Nat'l Conf. Artificial Intelligence, 2002.
- [66] S.E. Middleton, N.R. Shadbolt, and D.C. de Roure, "Ontological User Profiling in

- Recommender Systems,” *ACM Trans. Information Systems*, vol. 22, no. 1, pp. 54-88, 2004.
- [67] B.N. Miller, I. Albert, S.K. Lam, J.A. Konstan, and J. Riedl, “MovieLens Unplugged: Experiences with an Occasionally Connected Recommender System,” *Proc. Int’l Conf. Intelligent User Interfaces*, 2003.
- [68] B. Mobasher, H. Dai, T. Luo, and M. Nakagawa, “Discovery and Evaluation of Aggregate Usage Profiles for Web Personalization,” *Data Mining and Knowledge Discovery*, vol. 6, no. 1, pp. 61-82, 2002.
- [69] R.J. Mooney and L. Roy, “Content-Based Book Recommending Using Learning for Text Categorization,” *Proc. ACM SIGIR ’99 Workshop Recommender Systems: Algorithms and Evaluation*, 1999.
- [70] R.J. Mooney, P.N. Bennett, and L. Roy, “Book Recommending Using Text Categorization with Extracted Information,” *Proc. Recommender Systems Papers from 1998 Workshop*, Technical Report WS-98-08, 1998.
- [71] B.P.S. Murthi and S. Sarkar, “The Role of the Management Sciences in Research on Personalization,” *Management Science*, vol. 49, no. 10, pp. 1344-1362, 2003.
- [72] A. Nakamura and N. Abe, “Collaborative Filtering Using Weighted Majority Prediction Algorithms,” *Proc. 15th Int’l Conf. Machine Learning*, 1998.
- [73] G. Nurnberger, *Approximation by Spline Functions*. Springer-Verlag, 1989.
- [74] D.W. Oard and J. Kim, “Implicit Feedback for Recommender Systems,” *Proc. Recommender Systems. Papers from 1998 Workshop*, Technical Report WS-98-08, 1998.
- [75] D. Pavlov and D. Pennock, “A Maximum Entropy Approach to Collaborative Filtering in Dynamic, Sparse, High-Dimensional Domains,” *Proc. 16th Ann. Conf. Neural Information Processing Systems (NIPS ’02)*, 2002.
- [76] M. Pazzani, “A Framework for Collaborative, Content-Based, and Demographic Filtering,” *Artificial Intelligence Rev.*, pp. 393-408, Dec. 1999.
- [77] M. Pazzani and D. Billsus, “Learning and Revising User Profiles: The Identification of Interesting Web Sites,” *Machine Learning*, vol. 27, pp. 313-331, 1997.

- [78] C.C. Peddy and D. Armentrout, *Building Solutions with Microsoft Commerce Server* 2002. Microsoft Press, 2003.
- [79] D.M. Pennock and E. Horvitz, "Collaborative Filtering by Personality Diagnosis: A Hybrid Memory And Model-Based Approach," *Proc. Int'l Joint Conf. Artificial Intelligence Workshop: Machine Learning for Information Filtering*, Aug. 1999.
- [80] A. Popescul, L.H. Ungar, D.M. Pennock, and S. Lawrence, "Probabilistic Models for Unified Collaborative and ContentBased Recommendation in Sparse-Data Environments," *Proc. 17<sup>th</sup> Conf. Uncertainty in Artificial Intelligence*, 2001.
- [81] M.J.D. Powell, *Approximation Theory and Methods*. Cambridge Univ. Press, 1981.
- [82] N. Ramakrishnan, B.J. Keller, B.J. Mirza, A.Y. Grama, and G. Karypis, "Privacy Risks in Recommender Systems," *IEEE Internet Computing*, vol. 5, no. 6, pp. 54-62, Nov./Dec. 2001.
- [83] A.M. Rashid, I. Albert, D. Cosley, S.K. Lam, S.M. McNee, J.A. Konstan, and J. Riedl, "Getting to Know You: Learning New User Preferences in Recommender Systems," *Proc. Int'l Conf. Intelligent User Interfaces*, 2002.
- [84] S. Robertson and S. Walker, "Threshold Setting in Adaptive Filtering," *J. Documentation*, vol. 56, pp. 312-331, 2000.
- [85] J.J. Rocchio, "Relevance Feedback in Information Retrieval," *SMART Retrieval System—Experiments in Automatic Document Processing*, G. Salton, ed., chapter 14, Prentice Hall, 1971.
- [86] P. Resnick, N. Iakovou, M. Sushak, P. Bergstrom, and J. Riedl, "GroupLens: An Open Architecture for Collaborative Filtering of Netnews," *Proc. 1994 Computer Supported Cooperative Work Conf.*, 1994.
- [87] E. Rich, "User Modeling via Stereotypes," *Cognitive Science*, vol. 3, no. 4, pp. 329-354, 1979.
- [88] S. Rosset, E. Neumann, U. Eick, N. Vatnik, and Y. Idan, "Customer Lifetime Value Modeling and Its Use for Customer Retention Planning," *Proc. Eighth ACM SIGKDD Int'l Conf. Knowledge Discovery and Data Mining (KDD-2002)*, July 2002.

- [89] G. Salton, Automatic Text Processing. Addison-Wesley, 1989.
- [90] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl, "Application of Dimensionality Reduction in Recommender Systems—A Case Study," Proc. ACM WebKDD Workshop, 2000.
- [91] B. Sarwar, G. Karypis, J. Konstan, and J. Riedl, "Item-Based Collaborative Filtering Recommendation Algorithms," Proc. 10<sup>th</sup> Int'l WWW Conf., 2001.
- [92] R. Schaback and H. Wendland, "Characterization and Construction of Radial Basis Functions," Multivariate Approximation and Applications, N. Dyn, D. Leviatan, D. Levin, and A. Pinkus, eds., Cambridge Univ. Press, 2001.
- [93] J.B. Schafer, J.A. Konstan, and J. Riedl, "E-Commerce Recommendation Applications," Data Mining and Knowledge Discovery, vol. 5, nos. 1/2, pp. 115-153, 2001.
- [94] A.I. Schein, A. Popescul, L.H. Ungar, and D.M. Pennock, "Methods and Metrics for Cold-Start Recommendations," Proc. 25th Ann. Int'l ACM SIGIR Conf., 2002.
- [95] D.C. Schmittlein, D.G. Morrison, and R. Colombo, "Counting Your Customers: Who Are They and What Will They Do Next?" Management Science, vol. 33, no. 1, 1987.
- [96] G. Shani, R. Brafman, and D. Heckerman, "An MDP-Based Recommender System," Proc. 18th Conf. Uncertainty in Artificial Intelligence, Aug. 2002.
- [97] U. Shardanand and P. Maes, "Social Information Filtering: Algorithms for Automating 'Word of Mouth'," Proc. Conf. Human Factors in Computing Systems, 1995.
- [98] B. Sheth and P. Maes, "Evolving Agents for Personalized Information Filtering," Proc. Ninth IEEE Conf. Artificial Intelligence for Applications, 1993.
- [99] L. Si and R. Jin, "Flexible Mixture Model for Collaborative Filtering," Proc. 20th Int'l Conf. Machine Learning, Aug. 2003.
- [100] I. Soboroff and C. Nicholas, "Combining Content and Collaboration in Text Filtering," Proc. Int'l Joint Conf. Artificial Intelligence Workshop: Machine Learning for Information Filtering, Aug. 1999.
- [101] G. Somlo and A. Howe, "Adaptive Lightweight Text Filtering," Proc. Fourth Int'l

- Symp. Intelligent Data Analysis, 2001.
- [102] R.B. Statnikov and J.B. Matusov, *Multicriteria Optimization and Engineering*. Chapman & Hall, 1995.
- [103] L. Terveen, W. Hill, B. Amento, D. McDonald, and J. Creter, "PHOAKS: A System for Sharing Recommendations," *Comm. ACM*, vol. 40, no. 3, pp. 59-62, 1997.
- [104] T. Tran and R. Cohen, "Hybrid Recommender Systems for Electronic Commerce," *Proc. Knowledge-Based Electronic Markets, Papers from the AAAI Workshop*, Technical Report WS-00-04, AAAI Press, 2000.
- [105] L.H. Ungar and D.P. Foster, "Clustering Methods for Collaborative Filtering," *Proc. Recommender Systems, Papers from 1998 Workshop*, Technical Report WS-98-08 1998.
- [106] W. Wade, "A Grocery Cart that Holds Bread, Butter, and Preferences," *New York Times*, Jan. 16, 2003.
- [107] Y. Yang and B. Padmanabhan, "On Evaluating Online Personalization," *Proc. Workshop Information Technology and Systems*, pp. 35- 41, Dec. 2001.
- [108] K. Yu, X. Xu, J. Tao, M. Ester, and H.-P. Kriegel, "Instance Selection Techniques for Memory-Based Collaborative Filtering," *Proc. Second SIAM Int'l Conf. Data Mining (SDM '02)*, 2002.
- [109] K. Yu, A. Schwaighofer, V. Tresp, X. Xu, and H.-P. Kriegel, "Probabilistic Memory-Based Collaborative Filtering," *IEEE Trans. Knowledge and Data Eng.*, vol. 16, no. 1, pp. 56-69, Jan. 2004.
- [110] *Proc. WEBKDD 2002—Mining Web Data for Discovering Usage Patterns and Profiles*, O.R. Zai'ane, J. Srivastava, M. Spiliopoulou, B. M. Masand, eds., 2003.
- [111] Y. Zhang and J. Callan, "Maximum Likelihood Estimation for Filtering Thresholds," *Proc. 24th Ann. Int'l ACM SIGIR Conf.*, 2001.
- [112] Y. Zhang, J. Callan, and T. Minka, "Novelty and Redundancy Detection in Adaptive Filtering," *Proc. 25th Ann. Int'l ACM SIGIR Conf.*, pp. 81-88, 2002.